

Вопросы к коллоквиуму:

1. Цель обучения с подкрепления (RL). Сравнение с обучением с учителем и без учителя, преимущества RL и недостатки. Основные проблемы/сложности в RL. Основные термины RL: среда/агент, вознаграждение, наблюдение и состояние среды, почему разделяются понятие наблюдения и состояния.
2. Основные термины RL: стратегия, отдача. Формализация задачи обучения с подкреплением: что есть в условии, что из этого известно агенту, в чем цель обучения. Марковский процесс принятия решений (МППР).
3. Функция полезности состояний (V) и действий (Q): что это и зачем введены. Зависят ли функции полезности от стратегии агента? Уравнение Беллмана для функций полезности (обычные и оптимальности). Почему они важны в RL?
4. Варианты представления стратегии (явное и неявное). Жадная стратегия и ее возможное неявное представление. Проблема исследования и использования (exploration vs exploitation, XX дилемма).
5. Стратегии исследования: ϵ -greedy [с затуханием], softmax, UCB.
6. Монте-Карло подход для оценки полезности стратегии. Метод временных различий (Temporal Difference, TD) оценки полезности стратегии. В чем основная идея и различие этих двух подходов. Метод SARSA — из каких шагов состоит, как в нем оценивается функция полезности (шаг обновления)?
7. Алгоритм Q-обучения (Q-learning). В чем отличие между SARSA и Q-learning?
8. On-policy vs Off-policy подходы, в чем различие и какие у этого следствия.
9. Алгоритм DQN. Что оценивается нейронной сетью? Как обучается сеть? Как DQN связан с Q-learning? Целевая сеть и память прецедентов (replay buffer). Плюсы и минусы DQN.
10. Улучшения для DQN: prioritized replay buffer, Double DQN, Dueling DQN. В чем идея, какую проблему решают.
11. Value-based vs Policy-based методы: в чем концептуально различие, чем потенциально прямой поиск стратегии может быть лучше? Прямой поиск стратегии: что оценивается нейронной сетью,
12. Policy gradient (PG, понимание схемы вывода формулы), алгоритм vanilla REINFORCE, плюсы и минусы.
13. Базовые уровни для policy gradient: что это и зачем. Наиболее популярные примеры.
14. Модель актор-критика: что это и зачем, что является актором и критиком, в чем цель обучения каждого, как они взаимодействуют.
15. Алгоритм A2C: описание, что оценивается критиком, как оценивается функция преимущества.
16. n-step TD, TD(λ), GAE (General Advantage Estimate): что это за алгоритмы и какую проблему решают.
17. Алгоритмы актор-критиков NPG, TRPO, PPO: какую общую цель преследуют, кратко идея каждого, плюсы и минусы.
18. RL с непрерывными действиями: в чем отличие от дискретной задачи. Как выглядит адаптация алгоритмов на основе Policy Gradient? Можно ли адаптировать value-based алгоритмы, например, DQN?
19. Алгоритмы DDPG и TD3: в чем суть, Deterministic Policy Gradient (понимание схемы вывода формулы), как обновляются актор и критик (кто когда заморожен), преимущества и отличия друг от друга и от других актор-критиков?
20. Алгоритм SAC: идея, что оптимизируют актор и критик, сравнение с DDPG/TD3 (в частности, относительно исследования), плюсы и минусы алгоритма.