

Вопросы к экзамену:

Part 1

1. Цель обучения с подкрепления (RL). Сравнение с обучением с учителем и без учителя, преимущества RL и недостатки. Основные проблемы/сложности в RL. Основные термины RL: среда/агент, вознаграждение, наблюдение и состояние среды, почему разделяются понятие наблюдения и состояния.
2. Основные термины RL: стратегия, отдача. Формализация задачи обучения с подкреплением: что есть в условии, что из этого известно агенту, в чем цель обучения. Марковский процесс принятия решений (МППР).
3. Функция полезности состояний (V) и действий (Q): что это и зачем введены. Зависят ли функции полезности от стратегии агента? Уравнение Беллмана для функций полезности (обычные и оптимальности). Почему они важны в RL?
4. Варианты представления стратегии (явное и неявное). Жадная стратегия и ее возможное неявное представление. Проблема исследования и использования (exploration vs exploitation, XX дилемма).
5. Стратегии исследования: ϵ -greedy [с затуханием], softmax, UCB.
6. Монте-Карло подход для оценки полезности стратегии. Метод временных различий (Temporal Difference, TD) оценки полезности стратегии. В чем основная идея и различие этих двух подходов. Метод SARSA — из каких шагов состоит, как в нем оценивается функция полезности (шаг обновления)?
7. Алгоритм Q-обучения (Q-learning). В чем отличие между SARSA и Q-learning?
8. On-policy vs Off-policy подходы, в чем различие и какие у этого следствия.
9. Алгоритм DQN. Что оценивается нейронной сетью? Как обучается сеть? Как DQN связан с Q-learning? Целевая сеть и память прецедентов (replay buffer). Плюсы и минусы DQN.
10. Улучшения для DQN: prioritized replay buffer, Double DQN, Dueling DQN. В чем идея, какую проблему решают.
11. Value-based vs Policy-based методы: в чем концептуально различие, чем потенциально прямой поиск стратегии может быть лучше? Прямой поиск стратегии: что оценивается нейронной сетью,
12. Policy gradient (PG, понимание схемы вывода формулы), алгоритм vanilla REINFORCE, плюсы и минусы.
13. Базовые уровни для policy gradient: что это и зачем. Наиболее популярные примеры.
14. Модель актор-критика: что это и зачем, что является актором и критиком, в чем цель обучения каждого, как они взаимодействуют.
15. Алгоритм A2C: описание, что оценивается критиком, как оценивается функция преимущества.
16. n-step TD, TD(λ), GAE (Generalized Advantage Estimation): что это за алгоритмы и какую проблему решают.
17. Алгоритмы актор-критиков NPG, TRPO и PPO: какую общую цель они преследуют и почему возникает такая необходимость. Понятия естественного градиента и trust region. Алгоритм PPO: PPO-clipping и PPO-penalty, оценка преимущества (GAE), обучение актора и критика. Преимущества и недостатки алгоритмов.
18. RL с непрерывными действиями: в чем отличие от дискретной задачи. Как выглядит адаптация алгоритмов на основе Policy Gradient? Можно ли адаптировать value-based алгоритмы, например, DQN?
19. Алгоритмы DDPG и TD3: в чем суть, Deterministic Policy Gradient (понимание схемы вывода формулы), как обновляются актор и критик (кто когда заморожен), преимущества и отличия друг от друга и от других актор-критиков?

20. Алгоритм SAC: идея, что оптимизируют актор и критик, сравнение с DDPG/TD3 (в частности, относительно исследования), плюсы и минусы алгоритма.

Part 2

1. Goal-Conditioned Reinforcement Learning (GCRL): идея обучения единой стратегии для множества целей. Goal-conditioned policy и Universal Value Function Approximator (UVFA). Проблема разреженных вознаграждений и исследования среды в GCRL. Алгоритм Hindsight Experience Replay (HER): основная идея и преимущества. Роль выбора целей, их представления и распределения при обучении.
2. Иерархическое обучение с подкреплением (HRL): идея временной абстракции и многоуровневого принятия решений. Подцели, навыки (skills) и иерархические стратегии. В каких задачах HRL может быть полезно, а в каких преимущества иерархии ограничены. Современный взгляд на HRL: переход от явных иерархий к навыкам, Goal-Conditioned RL, world models и агентам на основе LLM/VLM.
3. Model-Based Reinforcement Learning (MBRL): в чем отличие от model-free RL. Что такое модель среды и для чего она может использоваться. Основные способы применения моделей: планирование, генерация синтетического опыта, исследование среды и обучение представлений. Алгоритм Dyna-Q: основная идея, преимущества и недостатки.
4. Планирование в обучении с подкреплением: отличие планирования от обучения. Идея поиска действий с использованием модели среды. Планирование с ограниченным горизонтом (MPC). Алгоритм Monte Carlo Tree Search (MCTS): основная идея, этапы selection, expansion, simulation и backup. Баланс исследования и использования в MCTS. Преимущества, недостатки и области применения MCTS.
5. Современные подходы Model-Based Reinforcement Learning (MBRL) и world models: идея обучения и использования модели мира для принятия решений. Обучение в воображаемых траекториях (imagination), преимущества и ограничения world models. Явные (explicit) и неявные (implicit) модели мира. Использование моделей мира для планирования, исследования среды и безопасного обучения.
6. Многоагентное обучение с подкреплением (MARL): чем отличается от классического RL. Кооперативные и конкурентные задачи. Проблемы нестационарности среды, координации действий, распределения ответственности (credit assignment) и исследования среды. Идея parameter sharing и Centralized Training, Decentralized Execution (CTDE). Роль self-play и популяционного обучения в современных системах MARL. Семейства независимого обучения агентов (например, IPPO) и методов с централизованным обучением (например, MAPPO, MADDPG), алгоритмы VDN/QMIX: кратко ключевая идея.
7. Безопасное обучение с подкреплением (Safe RL): отличие Constrained Markov Decision Process (CMDP) от MDP. Основные семейства методов Safe RL: оптимизация с ограничениями (напр, использование лагранжиана), shielding и корректировка действий, model-based подходы и world models. Основные проблемы/сложности Safe RL.
8. Память в обучении с подкреплением: почему классической постановки MDP часто недостаточно и как проблема частичной наблюдаемости (POMDP) приводит к необходимости использования памяти. Основные подходы к построению памяти в RL: рекуррентные модели, трансформеры, внешняя память и эпизодическая память. Их преимущества, ограничения и области применения.
9. Визуальное обобщение (visual generalization) в обучении с подкреплением: какие виды сдвига распределения могут возникать между обучением и тестированием. Почему агенты могут переобучаться на визуальные особенности среды. Аугментация данных как способ обучения инвариантным признакам. Идея поведенчески-инвариантных

представлений (behavioral similarity, bisimulation). Почему представления, полезные для функции полезности, могут отличаться от представлений, необходимых стратегии.

Подходы повышения способности к обобщению и их ограничения.

10. Vision-Language-Action (VLA) модели для обучения с подкреплением: идея объединения визуального восприятия, языка и действий в единой модели. Чем VLA отличаются от классических RL-агентов и Vision-Language Models (VLM). Роль предварительного обучения на больших наборах данных и последующей адаптации с помощью RL. Основные преимущества и ограничения.